

Sami MALEK

Data Scientist & Ingénieur IA

Rabat, Maroc
sami.malek15@gmail.com
+212 651 829 145
linkedin.com/in/malek-sami-089b44291/
github.com/SamiMalek10

PROFIL PROFESSIONNEL

Data Scientist et Ingénieur IA avec une expérience concrète sur l'ensemble du cycle de vie ML/IA — de la modélisation classique et des pipelines Big Data aux systèmes LLM en production et aux architectures multi-agents. Résultats mesurables : identification d'une opportunité de croissance de 55 millions de MAD dans le secteur pharmaceutique, amélioration de la rétention étudiante de 87 % grâce à une plateforme RAG agentique, et 98 % de précision sur la classification d'images médicales. Actuellement en charge de l'architecture d'une infrastructure LLM Gateway et de frameworks de gouvernance IA pour des déploiements en production. Diplôme d'ingénieur en Data Science & IA à l'ENSAM Rabat (promotion 2026).
Trilingue arabe, français, anglais.

EXPÉRIENCE PROFESSIONNELLE

GETEAM

Ingénieur AI/ML — Gestion de LLM Gateway

2026 (En cours)

6 mois · Télétravail

Conception d'une passerelle LLM centralisée pour gérer plusieurs fournisseurs de modèles avec un routage intelligent, une optimisation des coûts et une observabilité complète en production.

- Conception d'une couche de gestion LLM centralisée unifiant les APIs de plusieurs fournisseurs (OpenAI, Anthropic, Mistral) derrière une interface commune, réduisant la charge d'intégration pour les équipes métier.
- Implémentation d'un routage intelligent des requêtes avec optimisation des coûts et équilibrage de charge selon la complexité et les exigences de latence.
- Mise en place d'une stack d'observabilité : dashboards de monitoring temps réel, logs structurés et métriques LLM spécifiques (usage tokens, percentiles de latence, taux d'erreur, coût par requête).
- En cours : amélioration des performances, réduction des coûts et standardisation de l'accès aux modèles à l'échelle de la plateforme.

PM ACCELERATOR

Ingénieur IA — Gouvernance des Agents IA

2026

6 mois · Télétravail

Développement de GovernHQ, une couche de gouvernance et de sécurité qui intercepte et évalue les étapes de raisonnement des agents IA avancés avant leur exécution.

- Développement de GovernHQ : framework de gouvernance offrant des contrôles de sécurité et de conformité pour des agents IA autonomes en production.
- Ingénierie d'un système d'interception du raisonnement évaluant les plans d'action des agents en cours d'exécution et bloquant sélectivement les actions dangereuses ou non conformes.
- Conception d'un moteur de règles dynamiques avec filtres de décision configurables et workflows de supervision humaine pour les contextes réglementés.

COMPÉTENCES TECHNIQUES

Langages de Programmation

Python SQL / PL-SQL Java
JavaScript C++

ML & Deep Learning

Scikit-learn PyTorch
TensorFlow / Keras XGBoost
NumPy / Pandas
Matplotlib / Seaborn

NLP & LLMs

Hugging Face Transformers
BERT / GPT / Whisper NLLB-200
spaCy / NLTK PyTesseract

RAG, Agents & Systèmes LLM

FAISS / BM25
Systèmes Multi-agents
LLM Gateway & Routage
Gouvernance IA
Sentence Transformers

Vision par Ordinateur

OpenCV YOLOv8
Detectron2 / Faster R-CNN
ResNet / VGG / GANs

Big Data & Systèmes Distribués

Apache Spark (PySpark)
Hadoop / HDFS / Hive
Apache Kafka Flink / Flume / Storm
HBase

Bases de Données

PostgreSQL / MySQL / Oracle
MongoDB Elasticsearch Neo4j
SQLite

Cloud & DevOps

Docker Linux / Shell MLflow

LAPROPHAN

2025

Data Scientist — Analytique Client

3 mois · Casablanca, Maroc

Application de la segmentation client par apprentissage automatique sur des données de ventes pharmaceutiques pour identifier une opportunité de croissance de 55 M MAD dans un écosystème intégré SAP.

- Identification d'une opportunité de croissance de 55 millions de MAD par segmentation K-Means des clients sur données transactionnelles SAP, grâce à un modèle Valeur vs. Potentiel.
- Construction de tableaux de bord Power BI intégrant les flux SAP en temps réel pour fournir des insights commerciaux et de distribution actionnables à l'équipe commerciale.
- Développement de modèles de régression prédictive pour anticiper la demande par territoire et orienter les décisions de planification des stocks et de ciblage commercial.

3D SMART FACTORY

2025

Data Scientist — IA Agentique & RAG

3 mois · Mohammedia, Maroc

Conception et déploiement d'une plateforme RAG multi-agents 100 % locale pour l'apprentissage adaptatif, améliorant la rétention étudiante de 87 % et réduisant le temps d'étude de 30 % tout en garantissant la confidentialité des données.

- Architecture d'un système RAG multi-agents avec agents spécialisés : Q&R, génération automatique de quiz et planification d'étude adaptative selon le profil d'apprentissage.
- Construction d'un pipeline de récupération hybride combinant recherche vectorielle FAISS, récupération sparse BM25 et embeddings all-MiniLM-L6-v2 pour une précision de récupération maximale.
- Résultats mesurables : amélioration de 87 % de la rétention étudiante et réduction de 30 % du temps d'étude par rapport aux méthodes traditionnelles.
- Déployé en solution 100 % locale (aucun appel API cloud) garantissant la confidentialité totale des données — critère indispensable pour l'adoption institutionnelle.

ENSAM Rabat

Nov – Déc 2024

Formateur Technique

2 mois · Rabat, Maroc

Conception et animation d'ateliers pratiques sur les outils modernes d'ingénierie des données et de DevOps pour les étudiants ingénieurs.

- Animation d'ateliers pratiques sur Apache Kafka (streaming de données), Docker (conteneurisation) et Elasticsearch (recherche/indexation distribuée) pour des étudiants en cycle ingénieur.
- Création d'exercices structurés et de démonstrations live à partir de cas réels : ingestion événementielle, microservices conteneurisés et pipelines d'indexation distribuée.
- Formation Spring Boot avec démonstration d'architecture MVC en conditions réelles.

Ministère de la Justice, Maroc

Juil. 2024

Développeur — Plateforme NLP Judiciaire

1 mois · Rabat, Maroc

Co-développement d'une plateforme web de transcription et de traduction automatique des discours judiciaires en arabe, à l'aide de modèles de reconnaissance vocale et de NLP multilingue de pointe.

- Co-développement d'une plateforme web full-stack pour la transcription automatique et la traduction arabe des audiences judiciaires, adaptée aux exigences de précision du contexte juridique.
- Construction du pipeline NLP : Whisper-small pour la reconnaissance automatique de la parole en arabe, NLLB-200 pour la traduction neuronale, avec modules de traitement audio et conversion de texte.

PROJETS

JupyterHub

Développement Web

Flask / Django

React.js / Angular

Streamlit

Spring Boot

Bootstrap

Odoo ERP

IoT & Systèmes Embarqués

ESP32 / Arduino

Capteurs PIR / Actionneurs

Wokwi / Tinkercad

Protocoles & Architecture IoT

BI & Analytique

Power BI

Tableau

Talend

CERTIFICATIONS

Machine Learning Specialization

DeepLearning.AI / Coursera · 2024

Data Science and Machine Learning

Udemy · 2023

Introduction to Deep Learning with PyTorch

DataCamp · 2024

IBM Introduction to Computer Vision

IBM / Coursera · 2024

Introduction to Kafka

DataCamp · 2024

AI Career Essentials (x2)

Diverses plateformes · 2024

Applied Machine Learning Days 2024

AMLD Africa · 2024

LANGUES

Arabe

Langue maternelle

Français

Courant

Anglais

Courant

BÉNÉVOLAT

Responsable Logistique

Club Innovatech, ENSAM Rabat

2023 – 2026

Prédiction de la Valeur Marchande au Football

2024

✓ RMSE : 0,298

Pipeline ML de bout en bout sur infrastructure distribuée pour prédire la valeur marchande des joueurs de football à partir de données scrappées.

- RMSE de 0,298 obtenu avec un modèle d'ensemble combinant gradient boosting et régression sur données de performance et de marché.
- Traitement et analyse à grande échelle avec PySpark sur HDFS ; tableau de bord Streamlit interactif pour l'exploration et la prédiction en temps réel.

PySpark HDFS Scikit-learn Streamlit Python

Pipeline d'Analyse de Logs

2024

Système d'ingestion et d'analyse de logs distribué, construit sur l'écosystème Hadoop pour le traitement de journaux serveurs à grande échelle.

- Construction d'un pipeline de collecte de logs avec Apache Flume pour router les journaux serveurs vers HDFS à grande échelle.
- Analyse structurée par requêtes Hive SQL et jobs MapReduce personnalisés pour l'agrégation et la détection d'anomalies.

Hadoop HDFS Hive MapReduce Apache Flume

Plateforme Web de Transcription Judiciaire

2024

Application web de transcription et traduction automatique des audiences judiciaires en arabe, développée pour le Ministère de la Justice du Maroc.

- Application full-stack avec frontend React.js et backend Python/Flask pour le Ministère de la Justice.
- Intégration de Whisper-small pour la reconnaissance automatique de la parole et NLLB-200 pour la traduction neuronale arabe de haute qualité.

React.js JavaScript Python Flask Whisper-small NLLB-200

Classification de Tumeurs Cérébrales (Méningiome)

2024

✓ Précision : 98 %

Système de deep learning pour la classification des grades de méningiomes par apprentissage par transfert sur images IRM médicales — précision de niveau clinique.

- Précision de 98 % obtenue avec un ensemble de ResNet50, VGG16, VGG19 et un CNN personnalisé.
- Apprentissage par transfert et augmentation de données pour pallier la rareté des datasets d'imagerie médicale annotés.

Python TensorFlow Keras ResNet50 VGG16 VGG19 OpenCV

Détection de Fruits en Temps Réel (YOLOv8)

2024

Pipeline de détection d'objets en temps réel pour la reconnaissance multi-classes de fruits, basé sur un modèle YOLOv8 fine-tuné.

- Entraînement et optimisation de YOLOv8 pour la détection multi-classes de fruits dans des flux vidéo temps réel avec haute précision et rappel.
- Intégration d'OpenCV pour la capture vidéo, le prétraitement des images et le rendu des annotations.

Python YOLOv8 OpenCV Ultralytics

Application Web de Suivi de l'Alphabétisation

2023

Application web full-stack de suivi de la progression en lecture avec moteur de recommandation ML intégré par fouille de données.

- Backend Flask + SQLite avec frontend Bootstrap ; moteur de recommandation ML par filtrage collaboratif et fouille de données.

Flask SQLite Python Scikit-learn Bootstrap NumPy Pandas

Classification Multimodale de Documents Bancaires

2024

Projet de fin d'études en équipe : système automatisé de classification de documents bancaires (transaction vs. non-transaction) par pipeline NLP + Vision Transformer avec fusion tardive au niveau des scores — traitement PDF natifs et documents scannés.

- Architecture dual-pipeline : voie NLP (PyPDF2 + Tesseract OCR + NLTK Snowball Stemmer) et voie Vision (ViT — Vision Transformer), fusionnées par moyenne pondérée des scores.
- Service REST FastAPI pour exposer le moteur de classification ; architecture conçue pour gérer la diversité de qualité et de format des documents bancaires.

Python

FastAPI

ViT (Vision Transformer)

Tesseract OCR

NLTK

PyPDF2

PyTorch

Plateforme de Recrutement Intelligente

2024

Projet d'équipe : plateforme de recrutement intelligente avec architecture Big Data, matching candidat-offre par ML et microservices pour des workflows de recrutement évolutifs.

- Moteur de matching candidat-offre par vectorisation TF-IDF et similarité cosinus ; couche Redis pour accélérer les requêtes de classement à grande échelle.
- Backend microservices modulaire (FastAPI + MongoDB) conteneurisé avec Docker selon des principes MLOps orientés déploiement.

FastAPI

MongoDB

Redis

Docker

TF-IDF

Python

Scikit-learn

AvicennAi — Assistant Conversationnel Médical

2024

Projet SIH en équipe : chatbot IA pour le suivi personnalisé des patients — du benchmark de l'existant à un POC génératif NLP couvrant la compréhension des symptômes, les recommandations d'examens et l'interprétation des résultats.

- Benchmark de 4 chatbots médicaux (K Health, Symptomate, Mediktor, Florence) sur l'UX, l'engagement clinique et l'architecture technique pour définir une alternative ouverte.
- Développement d'un pipeline NLP génératif avec fine-tuning LLM ; déploiement POC sur Google Colab + Ngrok pour le service d'inférence en environnement contraint.

Python

Hugging Face Transformers

IA Générative (fine-tuning)

Google Colab

Ngrok

Application de Prédiction de Prix Immobiliers

2024

Application ML de bout en bout pour l'estimation immobilière en temps réel avec intervalles de confiance, visualisation de l'importance des variables et déploiement cloud conteneurisé.

- Entraînement d'un Random Forest Regressor ; exposition des prédictions via interface Gradio interactive avec intervalles de confiance et graphes d'importance des variables.
- Conteneurisé avec Docker et déployé sur Hugging Face Spaces — cycle ML complet de la génération de données au service en production.

Python

Scikit-learn

Random Forest

Gradio

Docker

Hugging Face Spaces

Système de Détection de Mouvement Connecté (IoT)

2024

Prototype IoT de sécurité pour la détection d'intrusion sur campus : système d'alarme basé ESP32 avec affichage local et alertes, validé par simulation matérielle.

- Conception du circuit objet connecté : ESP32 + capteur PIR HC-SR501 + buzzer + LED + LCD 16×2 pour la détection de mouvement et l'alarme locale en temps réel.
- Validation du workflow complet détection-alerte via simulation Wokwi et conception schématique Tinkercad avant déploiement du prototype physique.

ESP32

PIR HC-SR501

C/C++

Simulation Wokwi

Tinkercad

Configuration ERP Santé (Odoo)

2024

Projet de configuration ERP et modélisation des processus pour une clinique pluridisciplinaire sous Odoo Community : gestion des patients, RH, stocks, facturation et contrôle d'accès par rôles.

- Configuration des modules Odoo (Employés, Inventaire, Comptabilité, Rendez-vous, Site Web, Projet, Studio) avec contrôle d'accès par rôle et département.
- Modélisation des workflows cliniques avec Odoo Studio : cycle patient, planification des rendez-vous, gestion des stocks de médicaments et processus de facturation.

Odoo Community

Odoo Studio

Configuration ERP

Modélisation des Processus Métier

Spark ML & Streaming Temps Réel

2024

Travaux pratiques Big Data : pipelines Spark de bout en bout pour le ML par lot et le traitement de flux temps réel — classification, analyse de sentiment, clustering et ingestion Kafka.

- Construction de pipelines Spark MLlib/ML (classification Iris, analyse de sentiment, k-means) avec l'API DataFrames et comparaison avec l'ingénierie manuelle des features.
- Implémentation Spark Streaming avec sources socket, fichier et Kafka pour l'ingestion, la transformation et l'agrégation de données en temps réel.

Apache Spark

Spark MLlib

Spark Streaming

Apache Kafka

Scala

Python

Prévision de Tendances Météorologiques

2024

Projet data science combinant analyse exploratoire des données météo, prévision de tendances par séries temporelles et tableau de bord Streamlit pour des insights géospatiaux et temporels.

- Prétraitement et analyse exploratoire de données météo historiques (CSV) avec Pandas ; modèles de prévision de séries temporelles pour anticiper les tendances climatiques.
- Tableau de bord Streamlit interactif pour la visualisation des patterns météorologiques géospatiaux et la comparaison des résultats de prévision.

Python

Pandas

Jupyter

Streamlit

Prévision Séries Temporelles

Cloud Privé — JupyterHub Multi-Utilisateurs

2024

Projet cloud et virtualisation : plateforme notebook JupyterHub multi-utilisateurs avec espaces de travail persistants, déployée pour une infrastructure d'équipe partagée.

- Déploiement de JupyterHub avec Docker Compose ; configuration de l'isolation des utilisateurs, des volumes persistants et des variables d'environnement pour un environnement notebook cloud privé.
- Documentation du workflow de déploiement pas à pas avec validation des conteneurs et tests d'intégration pour l'onboarding de l'équipe.

JupyterHub

Docker

Docker Compose

Linux

MLOps : Suivi d'Expériences avec MLflow

2024

TP MLOps : suivi reproductible d'expériences ML dans un environnement entièrement conteneurisé avec MLflow, JupyterLab et orchestration Docker réseau.

- Mise en place d'un environnement multi-conteneurs (JupyterLab + serveur MLflow) via Docker networks ; entraînement et suivi d'expériences de classification Iris avec logging complet des paramètres, métriques et artefacts.
- Démonstration du cycle MLOps complet : setup conteneurisé → entraînement → tracking → comparaison des résultats dans l'interface MLflow.

MLflow

Docker

Docker Networks

JupyterLab

Python

Scikit-learn

FORMATION

ENSAM Rabat — École Nationale Supérieure d'Arts et Métiers**2023 – 2026 (Promo 2026)***Diplôme d'Ingénieur — Data Science & Intelligence Artificielle***Data Science & Apprentissage Automatique** : Python pour la Data Science & le ML, Statistiques & Analyse de Données, Machine Learning, Deep Learning**NLP & Systèmes IA** : Traitement du Langage Naturel, Agents IA & Automatisation, Vision par Ordinateur**Big Data & Systèmes Distribués** : Architecture Big Data, Écosystème Hadoop (Hive, HBase, Pig, Flume), Messagerie Distribuée (Kafka, Flink, Storm)**Cloud & DevOps** : Cloud Computing, Conteneurisation (Docker / Kubernetes), MLOps & Suivi d'Expériences (MLflow), Cloud Privé (JupyterHub)**Génie Logiciel** : Systèmes d'Information & Bases de Données, Technologies Web Avancées, Structures de Données & Algorithmique (C++), UML & Programmation Java, Spring Boot / Architecture MVC**Applications Métier** : Santé Numérique, Cybersécurité, Environnement d'Entreprise & Économie, ERP & Systèmes d'Information d'Entreprise (Odoo), Architecture IoT & Objets Connectés (ESP32)**ENSAM Rabat****2021 – 2023***Classes Préparatoires Intégrées (CPGE) — Mathématiques & Sciences de l'Ingénieur***Lycée Annakhil, Kénitra****2021***Baccalauréat — Mathématiques & Sciences de l'Ingénieur*